

# Curso de Métodos Numéricos

DEMAT, Universidad de Guanajuato

## Clase 10: Métodos de relajación para resolver SELs. Método de mínimos cuadrados

- Métodos de relajación.
- Métodos de sobrerelajación sucesiva (SOR).
- Métodos de mínimos cuadrados.

---

**MAT-251**

Dr. Joaquín Peña Acevedo  
CIMAT A.C.

**e-mail:** [joaquin@cimat.mx](mailto:joaquin@cimat.mx)

En ciertos casos, hacer que  $r_{i,i+1}^{(t)}$  sea cero puede ser una estrategia algo agresiva. Por ello se hace

$$x_i^{(t)} = x_i^{(t-1)} + \omega \frac{r_{ii}^{(t)}}{a_{ii}}$$

para algún  $\omega > 0$ .

Si  $0 < \omega < 1$ , se dice que el método es *sub-relajado*.

Si  $1 < \omega$ , se dice que el método es *sobrerelajado*, y su propósito es acelerar la convergencia.

# Método de sobrerelajación sucesiva (SOR)

Definimos un factor  $1 < \omega$ . Entonces

$$x_i^{(t)} = \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(t)} - \sum_{j=i+1}^n a_{ij} x_j^{(t-1)} \right) + (1 - \omega) x_i^{(t-1)}.$$

Para ver la separación de la matriz, sólo hay que reordenar los términos de la ecuación

$$a_{ii} x_i^{(t)} + \omega \sum_{j=1}^{i-1} a_{ij} x_j^{(t)} = \omega b_i - \omega \sum_{j=i+1}^n a_{ij} x_j^{(t-1)} + (1 - \omega) a_{ii} x_i^{(t-1)}.$$

$$(\mathbf{Q} - \omega \mathbf{L}) \mathbf{x}^{(t)} = [(1 - \omega) \mathbf{Q} + \omega \mathbf{U}] \mathbf{x}^{(t-1)} + \omega \mathbf{b}.$$

**Nota:** El método converge para  $0 < \omega < 2$  (  $|1 - \omega| < 1$  ).

## Ejemplo 1 (I)

**Ejemplo.** Consideremos el sistema con la matriz tridiagonal de tamaño  $n = 100$  en la que el método de Jacobi tiene una convergencia lenta.

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 & \cdots & 0 & 0 & 0 \\ -1 & 2 & -1 & \cdots & 0 & 0 & 0 \\ 0 & -1 & 2 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 2 & -1 & 0 \\ 0 & 0 & 0 & \cdots & -1 & 2 & -1 \\ 0 & 0 & 0 & \cdots & 0 & 1 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 0 \\ 1 \end{pmatrix}$$


Fijando la tolerancia en  $\tau = 10^{-5}$ , el número de iteraciones que realiza el algoritmo depende del parámetro  $\omega$ :

$\omega$	$\ \mathbf{Ax}^{(t)} - \mathbf{b}\ _2$	Iteraciones
0.8	$9.9957 \times 10^{-6}$	12172
1.0	$9.9978 \times 10^{-6}$	8114
1.2	$9.9920 \times 10^{-6}$	5409

En este caso el algoritmo diverge con  $\omega = 1.5$ .

## Ejemplo 1 (II)

La siguiente gráfica muestra el valor del error  $\|\mathbf{Ax}^{(t)} - \mathbf{b}\|_2$  dependiendo del parámetro  $\omega$ .



Unidad 4:

---

## Mínimos cuadrados lineales

# Matrices rectangulares

Sea  $\mathbf{A}$  una matriz  $m \times n$  y  $\mathbf{b}$  un vector de dimensión  $m$ . Tenemos que para

$$\mathbf{Ax} = \mathbf{b}$$

- si  $m > n$ , el sistema es sobredeterminado.
- si  $m < n$ , el sistema es subdeterminado.

Para matrices cuadradas,  $m = n$ , si  $\mathbf{A}$  es no singular, la solución es única,

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Para matrices rectangulares, hay que analizar cada caso.

# Gradientes de formas lineales y cuadráticas

Sean  $\mathbf{c}, \mathbf{x} \in \mathbb{R}^n$ , y  $\mathbf{A} \in \mathbb{R}^{n \times n}$ .

Queremos calcular  $\nabla(\mathbf{c}^\top \mathbf{x})$  y  $\nabla(\mathbf{x}^\top \mathbf{A} \mathbf{x})$ .

$$\nabla(\mathbf{c}^\top \mathbf{x}) = \mathbf{c}$$

$$\nabla(\mathbf{x}^\top \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

De lo anterior se sigue que el gradiente del error

$$E(\mathbf{x}) = \|\mathbf{A} \mathbf{x} - \mathbf{b}\|_2^2$$

es


$$\nabla E(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A} \mathbf{x} - 2\mathbf{A}^\top \mathbf{b}$$



# Introducción (I)

Consideramos una matriz  $\mathbf{A} = [a_{ij}] \in \mathbb{R}^{m \times n}$  con  $m > n$ .

- Lo usual es que el sistema sobredeterminado  $\mathbf{Ax} = \mathbf{b}$  no tenga solución.



- En lugar de tratar de resolver el sistema de ecuaciones, planteamos el problema de optimización

$$\mathbf{x}^* = \min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2^2 = \min_{\mathbf{x}} \sum_{i=1}^m \left( \sum_{j=1}^n a_{ij}x_j - b_i \right)^2.$$

- Si resulta que el valor mínimo de  $\|\mathbf{Ax}^* - \mathbf{b}\|_2^2$  es cero, entonces  $\mathbf{x}^*$  es solución del sistema de ecuaciones. En otro caso, sólo decimos que se obtuvo la mejor solución en el sentido de mínimos cuadrados.
- La solución del problema de mínimos cuadrados lineales es

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b}.$$

- Para que  $\mathbf{A}^\top \mathbf{A}$  sea no singular se requiere que  $\mathbf{A}$  sea de rango (columna) completo.
- Para resolver este sistema conviene aplicar el método de factorización de Cholesky.

# Sistemas sobredeterminados

Sea  $\mathbf{A} = [\mathbf{A}_1 \cdots \mathbf{A}_n] \in \mathbb{R}^{m \times n}$  con  $m > n$ , formada por las columnas  $\mathbf{A}_i$ .

En general, el sistema  $\mathbf{A}\mathbf{x} = \mathbf{b}$  puede no tener solución.


Por ello, tiene sentido calcular la solución de mínimos cuadrados,

$$\hat{\mathbf{x}} = \begin{pmatrix} \hat{x}_1 \\ \vdots \\ \hat{x}_m \end{pmatrix} = \arg \min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|^2.$$

que está dada por


$$\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b},$$

que tiene una interpretación geométrica.



## Caso particular: Ajuste de una recta (I)

Tenemos  $m$  puntos  $\{(x_i, y_i)\}$  y queremos hallar una recta que mejor los aproxime:



## Caso particular: Ajuste de una recta (II)

Esto es, queremos determinar la pendiente  $a$  y la ordenada al origen  $b$  tales que

$$y_i = ax_i + b + \epsilon_i, \quad i = 1, 2, \dots, m$$

Si definimos

$$\mathbf{A} = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_m & 1 \end{bmatrix}, \quad \mathbf{x} = \begin{pmatrix} a \\ b \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}, \quad \boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_m \end{pmatrix}$$

Entonces  $\boldsymbol{\epsilon} = \mathbf{y} - \mathbf{Ax}$  y podemos reescribir  $E(a, b)$  como

$$E(a, b) = \sum_{i=1}^m \epsilon_i^2 = \|\boldsymbol{\epsilon}\|_2^2 = \|\mathbf{Ax} - \mathbf{y}\|_2^2$$

$$\begin{aligned} E(a, b) &= (\mathbf{Ax} - \mathbf{y})^\top (\mathbf{Ax} - \mathbf{y}) = (\mathbf{x}^\top \mathbf{A}^\top - \mathbf{y}^\top) (\mathbf{Ax} - \mathbf{y}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} - 2\mathbf{y}^\top \mathbf{Ax} + \mathbf{y}^\top \mathbf{y} \end{aligned}$$

## Caso particular: Ajuste de una recta (III)

Entonces

$$\nabla E = 0 \quad \Rightarrow \quad \mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{y}$$


Para nuestro ejemplo, tenemos que  $m = 50$ , por lo que  $\mathbf{A} \in \mathbb{R}^{50 \times 2}$ .  
Además,  $\det(\mathbf{A}^T \mathbf{A}) = 6489.3$ , por lo que el sistema tiene solución única:

$$\mathbf{x} = \begin{pmatrix} 1.173 \\ 1.505 \end{pmatrix}$$

En realidad, los datos fueron generados tomando puntos sobre la recta con  $a = 1.2$  y  $b = 1.5$  y se les agregó ruido a la ordenada.

En la siguiente gráfica se muestra en azul la recta obtenida por mínimos cuadrados

## Caso particular: Ajuste de una recta (IV)



# Planteamiento general del caso lineal (I)

Supongamos que tenemos un conjunto con  $m$  puntos en  $\mathbb{R}^n$ :

$$\{ (x_{11}, x_{12}, \dots, x_{1n}), (x_{21}, x_{22}, \dots, x_{2n}), \dots, (x_{m1}, x_{m2}, \dots, x_{mn}) \}$$

A cada punto  $(x_{i1}, x_{i2}, \dots, x_{in})$  lo tenemos asociado a una observación  $y_i$ .

$$(x_{i1}, x_{i2}, \dots, x_{in}) \mapsto y_i$$

El objetivo es determinar los coeficientes  $c_0, c_1, \dots, c_n$  un modelo que cumpla con:

$$y_i = c_0 + c_1 x_{i1} + \dots + c_n x_{in} + \epsilon_i$$

donde  $\epsilon_i$  es un error que tiene el modelo. Entonces

$$\epsilon_i = y_i - c_0 - \sum_{j=1}^n c_j x_{ij}$$

Queremos calcular los coeficientes  $c_j$  minimizando los errores  $\epsilon_i$ . Una manera es resolver el problema



## Planteamiento general del caso lineal (II)

$$\min_{c_0, \dots, c_n} E(c_0, c_1, \dots, c_n) = \sum_{i=1}^m \epsilon_i^2 = \sum_{i=1}^m \left( y_i - c_0 - \sum_{j=1}^n c_j x_{ij} \right)^2$$

Si definimos

$$\mathbf{A} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1n} \\ 1 & x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix}, \quad \mathbf{c} = \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}, \quad \boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_m \end{pmatrix}$$

Entonces

$$\mathbf{y} = \mathbf{A}\mathbf{c} + \boldsymbol{\epsilon}$$

$$\min_{c_0, \dots, c_n} E(\mathbf{c}) = \sum_{i=1}^m \epsilon_i^2 = \boldsymbol{\epsilon}^T \boldsymbol{\epsilon} = (\mathbf{y} - \mathbf{A}\mathbf{c})^T (\mathbf{y} - \mathbf{A}\mathbf{c})$$

## Planteamiento general del caso lineal (III)

Calculamos  $\nabla E(\mathbf{c})$  y el vector  $\mathbf{c}$  para el cual  $\nabla E(\mathbf{c}) = \mathbf{0}$ .

Se puede ver que la solución se obtiene resolviendo el sistema lineal



$$\mathbf{A}^T \mathbf{A} \mathbf{c} = \mathbf{A}^T \mathbf{y}.$$

**Ejemplo.** Consideramos un conjunto de 125 puntos en el espacio 3D  $\{(x_i, y_i, z_i)\}_{i=1}^{125}$ . Se realiza la estimación de los coeficientes  $c_0, c_1$  y  $c_2$  del modelo:

$$z_i = c_0 + c_1 x_i + c_2 y_i + \epsilon_i, \quad i = 1, 2, \dots, 125.$$


La siguiente gráfica muestra el resultado del ajuste:

## Planteamiento general del caso lineal (IV)



El color que se asigna a los puntos depende del lado del semiplano en que está.

# Planteamiento general del caso lineal (V)



## Lo que NO estamos haciendo

No es que estemos planteando resolver el sistema sobredeterminado

$$\mathbf{A}\mathbf{c} = \mathbf{y}$$

y para resolverlo multiplicamos por  $\mathbf{A}^T$  ambos miembros de la ecuación, pues el sistema puede ser inconsistente, por lo que podría no existir  $\mathbf{c}$  que cumpla la igualdad.

Para el ejemplo anterior, tenemos que con

$$c_0^* = 0.9029, \quad c_1^* = 0.8608, \quad c_2^* = -0.4621.$$


se tiene un error  $E(c_0^*, c_1^*, c_2^*) = \sum_{i=1}^m e_i^2 = 6.7787$ .

En ocasiones conviene reportar la raíz del error cuadrático medio (en inglés: *root mean square error*, RMSE):

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m \left( y_i - \sum_{j=1}^n a_{ij} c_j \right)^2}, \quad RMSE = \sqrt{\frac{1}{m} E(c_0^*, c_1^*, c_2^*)} \approx 0.37$$

# Ajuste de una recta general (I)

Tenemos un conjunto de puntos  $\{\mathbf{x}_i\}_{i=1}^m$ , con  $\mathbf{x}_i = (x_i, y_i)^T$ . El modelo  $y = ax + b$  no sirve para el siguiente conjunto de datos.



## Ajuste de una recta general (II)

Usamos la siguiente formulación:

Sea  $\bar{\mathbf{x}} = (\bar{x}, \bar{y})^T$  el centroide de los puntos,

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, \quad \bar{y} = \frac{1}{m} \sum_{i=1}^m y_i.$$

Idealmente  $\bar{\mathbf{x}}$  debería estar sobre la recta que vamos a ajustar, de modo que si  $\mathbf{x}$  es otro punto sobre la recta, se debe tener que

$$\mathbf{n}^T (\mathbf{x} - \bar{\mathbf{x}}) = 0.$$

Como los datos no están sobre una recta, debemos tener

$$\epsilon_i = (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{n} = [x_i - \bar{x} \quad y_i - \bar{y}] \mathbf{n} \quad i = 1, \dots, m.$$

Si definimos

$$\boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_m \end{pmatrix} = \begin{bmatrix} x_1 - \bar{x} & y_1 - \bar{y} \\ \vdots & \vdots \\ x_m - \bar{x} & y_m - \bar{y} \end{bmatrix} \mathbf{n} = \mathbf{A} \mathbf{n}$$

## Ajuste de una recta general (III)

Entonces queremos minimizar

$$\min \sum_{i=1}^m \epsilon_i^2 = \|\boldsymbol{\epsilon}\|^2 = \boldsymbol{\epsilon}^\top \boldsymbol{\epsilon} = \mathbf{n}^\top \mathbf{A}^\top \mathbf{A} \mathbf{n}$$

Note que

- La matriz  $\mathbf{A}^\top \mathbf{A}$  es semidefinida positiva.
- Falta agregar una condición al problema. Así como está planteado el problema, el vector  $\mathbf{n} = \mathbf{0}$  es solución.

Pedimos que, por ejemplo,  $\|\mathbf{n}\| = 1$ . Esto equivale a pedir que  $\mathbf{n}^\top \mathbf{n} = 1$ . Entonces el problema que queremos resolver es

$$\min \mathbf{n}^\top \mathbf{A}^\top \mathbf{A} \mathbf{n} \quad \text{sujeto a} \quad \mathbf{n}^\top \mathbf{n} = 1.$$

Para resolverlo, construimos la función Lagrangiana

$$\mathcal{L}(\mathbf{n}, \lambda) = \mathbf{n}^\top \mathbf{A}^\top \mathbf{A} \mathbf{n} - \lambda(\mathbf{n}^\top \mathbf{n} - 1).$$



## Ajuste de una recta general (IV)

Calculamos su gradiente e igualamos a cero:

$$2\mathbf{A}^T \mathbf{A} \mathbf{n} - 2\lambda \mathbf{n} = 0 \quad \Rightarrow \quad \mathbf{A}^T \mathbf{A} \mathbf{n} = \lambda \mathbf{n}$$

Esto es, la solución es un eigenvector de la matriz  $\mathbf{A}^T \mathbf{A}$ .


Si sustituimos en la función de error tenemos

$$\mathbf{n}^T \mathbf{A}^T \mathbf{A} \mathbf{n} = \mathbf{n}^T (\lambda \mathbf{n}) = \lambda \mathbf{n}^T \mathbf{n} = \lambda$$

Por lo tanto, el error mínimo se obtiene si elegimos  $\mathbf{n}$  como el eigenvector asociado al eigenvalor más pequeño.

Para cada conjunto de datos, se obtienen los resultados siguientes:

## Ajuste de una recta general (V)



Eigenvalores:

$$\lambda_1 = 0.6054, \lambda_2 = 61.324$$


Eigenvectores

$$\mathbf{v}_1 = \begin{pmatrix} -0.9998 \\ 0.0171 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} 0.0171 \\ 0.9998 \end{pmatrix}$$


Así,  $\mathbf{n} = \mathbf{v}_1$ .

Este enfoque se puede aplicar a cualquier conjunto de datos que puedan ser aproximados por un modelo lineal, por ejemplo:

# Ajuste de una recta general (VI)



## Ajuste de una recta general (VII)



Eigenvalores:

$$\lambda_1 = 0.4466, \lambda_2 = 64.785$$

Eigenvectores

$$\mathbf{v}_1 = \begin{pmatrix} -0.663 \\ -0.749 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} -0.749 \\ 0.663 \end{pmatrix}$$

Así,  $\mathbf{n} = \mathbf{v}_1$ .

## Observación (I)

Dado el conjunto de puntos  $\{\mathbf{x}_1, \dots, \mathbf{x}_m\}$  con  $\mathbf{x}_i = \begin{pmatrix} x_i \\ y_i \end{pmatrix}$ , resolver el problema


$$\min_{a,b} \sum_{i=1}^m (ax_i + b - y_i)^2$$

no da el mismo resultado que resolver el problema

$$\min_{\mathbf{n}} \sum_{i=1}^m [\mathbf{n}^T (\mathbf{x}_i - \bar{\mathbf{x}})]^2 \quad \text{sujeto a} \quad \mathbf{n}^T \mathbf{n} = 1.$$

En el primer caso la solución disminuye la suma de los cuadrados de las diferencias entre las ordenadas de los puntos  $(x_i, y_i)$  y  $(x_i, ax_i + b)$ , es decir, entre el dato y lo que predice el modelo.


## Observación (III)



En el segundo caso la solución disminuye la suma de los cuadrados de las proyecciones de los vectores  $\mathbf{x}_i - \bar{\mathbf{x}}$  sobre la dirección  $\mathbf{n}$ , es decir, de las “distancias con signo” de los puntos  $\mathbf{x}_i$  a la recta.



## Observación (V)



## Observación (VI)

Para la estimación de pendiente  $a$  y la ordenada al origen  $b$  se obtiene la recta

$$y_{a,b}(x) = -0.87417x + 1.0409,$$


con un error  $\sum_{i=1}^m \epsilon_i^2 = 0.792$ , donde  $\epsilon_i = ax_i + b - y_i$ .

---

Para la estimación del vector ortogonal  $\mathbf{n}$  se obtiene la recta


$$y_{\mathbf{n}}(x) = -0.88499x + 1.0573,$$

con un error  $\sum_{i=1}^m \epsilon_i^2 = 0.446$ , donde  $\epsilon_i = \mathbf{n}^T(\mathbf{x}_i - \bar{\mathbf{x}})$ .




# Sensibilidad de la solución por datos atípicos (I)

Sin datos atípicos, la solución de mínimos cuadrados proporciona un buen ajuste a los datos:




## Sensibilidad de la solución por datos atípicos (II)

Sin embargo, un solo dato atípico puede modificar la solución del problema de mínimos cuadrados:



## Sensibilidad de la solución por datos atípicos (III)

Entre más atípico sea el dato, mayor es el cambio en la solución del problema de mínimos cuadrados:



## Sensibilidad de la solución por datos atípicos (IV)

Para reducir el efecto que tienen los datos atípicos, se puede agregar un peso  $w_i > 0$  a cada termino de la suma de cuadrados:

$$E(a, b) = \sum_{i=1}^m w_i (ax_i + b - y_i)^2$$

de modo que a los términos que introducen errores grandes se les da un menor peso.


Esto nos lleva a un problema de *mínimos cuadrados pesados*.  
En el ejemplo, cuando todos los pesos son  $w_i = 1$ , se tiene

$$a^* = -0.277, \quad b^* = 1.945$$

Si cambiamos el peso del dato atípico a  $w_{49} = 0.01$ , se obtiene

$$a^* = 0.742, \quad b^* = 0.994$$

## Sensibilidad de la solución por datos atípicos (V)



# Mínimos cuadrados pesados (I)

Se puede escribir el error

$$E(a, b) = \sum_{i=1}^m w_i (ax_i + b - y_i)^2$$

introduciendo las matrices y vectores

$$\mathbf{W} = \text{diag}(w_1, \dots, w_m), \quad \mathbf{A} = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_m & 1 \end{bmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}, \quad \mathbf{c} = \begin{pmatrix} a \\ b \end{pmatrix}.$$

$$\begin{aligned} E(\mathbf{c}) &= (\mathbf{Ac} - \mathbf{y})^\top \mathbf{W} (\mathbf{Ac} - \mathbf{y}) = (\mathbf{c}^\top \mathbf{A}^\top - \mathbf{y}^\top) \mathbf{W} (\mathbf{Ac} - \mathbf{y}) \\ &= \mathbf{c}^\top \mathbf{A}^\top \mathbf{W} \mathbf{Ac} - 2\mathbf{y}^\top \mathbf{W} \mathbf{Ac} + \mathbf{b}^\top \mathbf{W} \mathbf{b}. \end{aligned}$$

Por tanto, la solución de mínimos cuadrados está dada al resolver el sistema

$$\mathbf{A}^\top \mathbf{W} \mathbf{Ac} = \mathbf{A}^\top \mathbf{W} \mathbf{y}.$$

El problema es como fijar los pesos  $w_1, \dots, w_m$  asociados a cada ecuación. El método de mínimos cuadrados pesados hace la siguiente propuesta:



## Mínimos cuadrados pesados (II)

- 1 Inicializar  $k = 0$ , los pesos  $w_i = 1$  y formar la matriz  $\mathbf{W}^{(0)}$ .
- 2 Calcular la solución del problema de mínimos cuadrados

$$\mathbf{A}^\top \mathbf{W}^{(k)} \mathbf{A} \mathbf{c}^{(k)} = \mathbf{A}^\top \mathbf{W}^{(k)} \mathbf{y}.$$

- 3 Calcular el vector de error  $\boldsymbol{\epsilon} = \mathbf{A} \mathbf{c}^{(k)} - \mathbf{y}$ .
- 4 Si  $\|\mathbf{c}^{(k)} - \mathbf{c}^{(k-1)}\|$  o el RMSE  $\sqrt{\frac{\boldsymbol{\epsilon}^\top \mathbf{W} \boldsymbol{\epsilon}}{m}}$  es menor que la tolerancia dada, terminar el algoritmo devolviendo la solución  $\mathbf{c}^{(k)}$ .
- 5 En caso contrario, modificar el valor del peso  $w_i$  de acuerdo a la magnitud de la componente  $i$ -ésima del vector de error,  $\epsilon_i = (\mathbf{A} \mathbf{c})_i - y_i$ , de modo que si  $\epsilon_i$  es grande, el peso  $w_i$  debe ser pequeño, y viceversa. Construir la matriz  $\mathbf{W}^{(k+1)}$ . Hacer  $k = k + 1$  y volver al paso 2.

## Ejemplo de mínimos cuadrados pesados (I)

Consideramos el problema de ajustar una recta a un conjunto de puntos  $\{(x_1, y_1), \dots, (x_m, y_m)\}$  en el plano aplicando el método de mínimos cuadrados pesados.

Una vez que se tiene una solución  $\mathbf{c}^{(k)}$  en la iteración  $k$ , actualizamos el valor de los pesos  $w_i^{(k+1)}$  se actualiza para la siguiente iteración mediante:

$$w_i^{(k+1)} = \exp(-5\epsilon_i^2), \quad \text{con } \epsilon_i = (\mathbf{A}\mathbf{c}^{(k)})_i - y_i.$$


La tolerancia usada es  $\tau = \sqrt{\epsilon_m}$ .

En las siguientes gráficas se muestra el resultado de aplicar el método de mínimos cuadrados pesados.

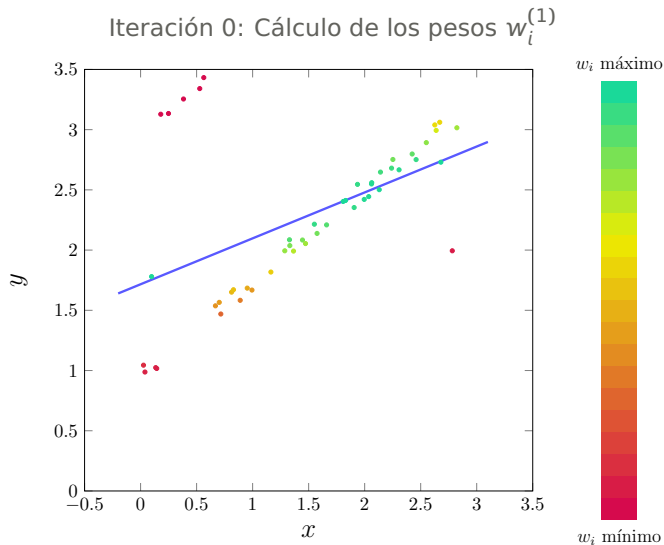
Los puntos son coloreados de acuerdo al valor del peso  $w_i$  que tienen asociado.

## Ejemplo de mínimos cuadrados pesados (II)

Iteración 0: Cálculo de la solución  $\mathbf{A}^T \mathbf{W}^{(0)} \mathbf{A} \mathbf{c}^{(0)} = \mathbf{A}^T \mathbf{W}^{(0)} \mathbf{y}$  con  $w_i^{(0)} = 1$




## Ejemplo de mínimos cuadrados pesados (III)




## Ejemplo de mínimos cuadrados pesados (IV)

Iteración 1: Cálculo de la solución  $\mathbf{A}^\top \mathbf{W}^{(1)} \mathbf{A} \mathbf{c}^{(1)} = \mathbf{A}^\top \mathbf{W}^{(1)} \mathbf{y}$




## Ejemplo de mínimos cuadrados pesados (V)

Iteración 1: Cálculo de los valores los pesos  $w_i^{(2)}$




## Ejemplo de mínimos cuadrados pesados (VI)

Iteración 2: Cálculo de la solución  $\mathbf{A}^T \mathbf{W}^{(2)} \mathbf{A} \mathbf{c}^{(2)} = \mathbf{A}^T \mathbf{W}^{(2)} \mathbf{y}$



## Ejemplo de mínimos cuadrados pesados (VII)


Iteración 2: Actualización de los valores los pesos  $w_i^{(3)}$





## Ejemplo de mínimos cuadrados pesados (VIII)

Iteración 10: Cálculo de la solución  $\mathbf{A}^T \mathbf{W}^{(10)} \mathbf{A} \mathbf{c}^{(10)} = \mathbf{A}^T \mathbf{W}^{(10)} \mathbf{y}$



## Ejemplo de mínimos cuadrados pesados (IX)

- El método de mínimos cuadrados pesados no siempre funciona.
- El método depende de la solución en la primera iteración y de la manera en la que se asignan los pesos.


Por ejemplo, si se cambia la manera de calcular los pesos de la siguiente manera:

$$w_i^{(k+1)} = \exp(-150\epsilon_i^2), \quad \text{con } \epsilon_i = (\mathbf{A}\mathbf{c}^{(k)})_i - y_i,$$

se obtiene los siguientes resultados.


# Ejemplo de mínimos cuadrados pesados (X)

Iteración 0: Cálculo de la solución  $\mathbf{A}^T \mathbf{W}^{(0)} \mathbf{A} \mathbf{c}^{(0)} = \mathbf{A}^T \mathbf{W}^{(0)} \mathbf{y}$  con  $w_i^{(0)} = 1$




# Ejemplo de mínimos cuadrados pesados (XI)

Iteración 0: Actualización de los valores de pesos  $w_i^{(1)}$




## Ejemplo de mínimos cuadrados pesados (XII)

Iteración 1: Cálculo de la solución  $\mathbf{A}^\top \mathbf{W}^{(1)} \mathbf{A} \mathbf{c}^{(1)} = \mathbf{A}^\top \mathbf{W}^{(1)} \mathbf{y}$



## Ejemplo de mínimos cuadrados pesados (XIII)

Iteración 1: Actualización de los valores los pesos  $w_i^{(2)}$



## Ejemplo de mínimos cuadrados pesados (XIV)

Iteración 118: Cálculo de la solución  $\mathbf{A}^T \mathbf{W}^{(118)} \mathbf{A} \mathbf{c}^{(118)} = \mathbf{A}^T \mathbf{W}^{(118)} \mathbf{y}$

