

Proyecto

December 16, 2020

1 Proyecto final

Proyecto final de **Metodos Numericos** del curso impartido en *Ago - Dic 2020*.

2 Redes Neuronales “feedforward”

Benjamin Rivera

2.1 Historia de las redes neuronales

1958 - Perceptron Frank Rosenblatt

- Concepto de *pesos*

1965 - Perceptron multicapa

- Umbrales fijos
- Valores binarios

1980 - Aprendizaje automatico

1986 – Backpropagation

Modernidad

- 1989 Redes Neuronales Convolucionales
- 1997 Long Short Term Memory (LSTM) y Redes Neuronales Recurrentes

Era de hielo

Deep Learning

- Transformers
- Deepe Learning
- Autoencoders
- Redes Adversarias
- Restricted Boltzmann Machines ()

2.2 Clasificación de las redes neuronales

Por capa

- Monocapa (red de Hopfield)
- Multicapa

Por topología

- Feedforward
- Recurrente (LSTM)
- Convolucionales

Por tipo de entrenamiento

- Por iluminación divina (Estocástico o matemático)
- Aprendizaje supervisado (Backpropagation)
- Aprendizaje no supervisado (Redes adversarias)
- Aprendizaje por refuerzo

2.3 En este trabajo ...

Se tratará de implementar una red neuronal feedforward con una estrategia de aprendizaje de *backpropagation*; por lo que trabajaremos en un ambiente de *entrenamiento supervisado*.

Perceptron

$$\sum_{i=1}^{i=q} w_i * p_i$$

Back propagation

1. Identificación de la diferencia entre el estímulo y la aproximación de la red
2. actualización de los pesos por el porcentaje del gradiente.

Para el cálculo de diferencias y gradiente

```
for l in range(len(a) - 2, 0, -1):  
    deltas.append(deltas[-1].dot(self.weights[l].T)*self.activation_prime(a[l]))
```

backpropagation

```
for i in range(len(self.weights)):  
    layer = np.atleast_2d(a[i])  
    delta = np.atleast_2d(deltas[i])  
    self.weights[i] += learning_rate * layer.T.dot(delta)
```

2.3.1 Implementación

Para la implementación de este proyecto unicmanete se usará la librería **numpy**.

```
[1]: import numpy as np
```

Mejores alternativas

- Keras
- PyTorch
- TensorFlow
- scikit-learn

```
[2]: # Funciones de Activacion
def relu(x):
    return 0 if x <= 0 else x

def relu_derivada(x):
    # Simplificacion para evitar errores.
    return 0 if x <= 0 else 1

def step(x):
    return 0 if x < 0 else 1

def step_derivada(x):
    # Simplificacion para evitar errores.
    return 0

def sigmoid(x):
    return 1.0/(1.0 + np.exp(-x))

def sigmoid_derivada(x):
    return sigmoid(x)*(1.0-sigmoid(x))

def tanh(x):
    return np.tanh(x)

def tanh_derivada(x):
    return 1.0 - x**2
```

```
[3]: class NeuralNetwork:
    """ Clase para generalizar redes neuronales feedforward.

    Esta clase tiene como objetivo la generalizacion de las redes neurona_
    les feedforward. Esta generalizacion no permite hacer modificaciones
    a la estructura estandar donde todos los nodos (a exeption de los de
    salida) se comportan como perceptrones conectados a las siguientes
    capas.

    Se tiene un unico constructor que inicializa todo como se pide
    """

    def __init__(self, layers, activation='tanh', w_range = (-1,1)):
        # Verificacion de datos de entrada
```

```

if activation not in ['sigmoid', 'tanh', 'relu', 'step']:
    raise Exception("Funcion de activacion no reconocida. ")
if w_range[0] >= w_range[1]:
    raise Exception("Error en el rango de los pesos. ")

# Seleccion de funcion de activacion
if activation == 'relu':
    self.activation = relu
    self.activation_prime = relu_derivada
elif activation == 'step':
    self.activation = step
    self.activation_prime = step_derivada
elif activation == 'sigmoid':
    self.activation = sigmoid
    self.activation_prime = sigmoid_derivada
elif activation == 'tanh':
    self.activation = tanh
    self.activation_prime = tanh_derivada

# Inicializacion de pesos
self.weights = []
self.deltas = []
# valores aleatorios a pesos de entrada y capa oculta
for i in range(1, len(layers) - 1):
    r = np.random.uniform(w_range[0], w_range[1], (layers[i-1] + 1,
↳layers[i] + 1))
    self.weights.append(r)
# valores aleatorios a capa de salida
r = np.random.uniform(w_range[0], w_range[1], (layers[i] + 1,
↳layers[i+1]))
self.weights.append(r)

def fit(self, X, y, learning_rate=0.1, epochs=100000):
    """ Funcion para realizar la aproximacion del modelo a los datos dados.

Esta funcion trata de ajustar los pesos de la red (backpropagation) para
que se ajuste a los datos dados. Permite que se ajuste el "ratio de
aprendizaje" y la cantidad de iteraciones para el entrenamiento.

Input:
    X := Datos de la capa de entrada
    y := Datos esperados en la capa de salida
    learning_rate := Ratio de aprendizaje del modelo
    epochs := Cantidad de iteraciones para el modelo
    """

```

```

# Agregacion de bias a capa de entrada
ones = np.atleast_2d(np.ones(X.shape[0]))
X = np.concatenate((ones.T, X), axis=1)

for k in range(epochs):
    i = np.random.randint(X.shape[0])
    a = [X[i]]

    for l in range(len(self.weights)):
        dot_value = np.dot(a[l], self.weights[l])
        activation = self.activation(dot_value)
        a.append(activation)

    # Calculo del error en el modelo
    error = y[i] - a[-1]
    deltas = [error * self.activation_prime(a[-1])]

    # Calculamos los deltas
    for l in range(len(a) - 2, 0, -1):
        deltas.append(deltas[-1].dot(self.weights[l].T)*self.
→activation_prime(a[l]))
    self.deltas.append(deltas)
    deltas.reverse()

    # backpropagation
    for i in range(len(self.weights)):
        layer = np.atleast_2d(a[i])
        delta = np.atleast_2d(deltas[i])
        self.weights[i] += learning_rate * layer.T.dot(delta)

    if k % 5000 == 0: print('epochs:', k)

def evaluate(self, x):
    """ Funcion para evaluar una entrada en la red. """
    ones = np.atleast_2d(np.ones(x.shape[0]))
    a = np.concatenate((np.ones(1).T, np.array(x)), axis=0)
    for l in range(0, len(self.weights)):
        a = self.activation(np.dot(a, self.weights[l]))
    return a

def set_weights(self, w):
    """ Funcion establecer ciertos pesos. """
    try:
        if w.shape == self.weights.shape:
            self.weights = w
    except AttributeError as e:
        print("Los pesos se mantienen. ")

```

```

        print(e)

    # Getters
    def get_weights(self):
        return self.weights

    def get_deltas(self):
        return self.deltas

```

```

[22]: def fast_training(X, y, hidden_layers=[3], epochs=15000, learning_rate=0.02,
    ↪activation='tanh'):
    """ Implementacion simplificada. """
    layers = [len(X[0]), len(y[0])]
    for lay in hidden_layers:
        layers.insert(-1, lay)

    nn = NeuralNetwork(layers, activation=activation)
    nn.fit(X, y, learning_rate=learning_rate, epochs=epochs)

    for i in range(len(X)):
        print("X:", X[i], "y:", y[i], "\n\tAproximacion: ", nn.evaluate(X[i]))

```

2.3.2 Ejemplos

- Compuerta logica NOT
- Compuerta logica AND
- Compuerta logica OR
- Compuerta logica XOR - Compuerta logica AND

Not

```

[23]: # Not
X = np.array([[0],
              [1]])

y = np.array([[1],
              [0]])

```

```

[24]: fast_training(X, y)

```

```

epochs: 0
epochs: 5000
epochs: 10000
X: [0] y: [1]
    Aproximacion: [0.97880185]
X: [1] y: [0]
    Aproximacion: [0.00051898]

```

```
[7]: fast_training(X, y, epochs=5001)
```

```
epochs: 0
epochs: 5000
X: [0] y: [1]
    Aproximacion: [0.95406978]
X: [1] y: [0]
    Aproximacion: [0.00098776]
```

```
[8]: fast_training(X, y, epochs=25001)
```

```
epochs: 0
epochs: 5000
epochs: 10000
epochs: 15000
epochs: 20000
epochs: 25000
X: [0] y: [1]
    Aproximacion: [0.98385756]
X: [1] y: [0]
    Aproximacion: [0.00014997]
```

And

```
[9]: # And
X = np.array([[0, 1],
              [0, 0],
              [1, 0],
              [1, 1]])

y = np.array([[0],
              [0],
              [0],
              [1]])
```

```
[10]: fast_training(X, y)
```

```
epochs: 0
epochs: 5000
epochs: 10000
X: [0 1] y: [0]
    Aproximacion: [0.0011221]
X: [0 0] y: [0]
    Aproximacion: [-0.00148757]
X: [1 0] y: [0]
    Aproximacion: [0.00260917]
X: [1 1] y: [1]
    Aproximacion: [0.96141139]
```

```
[11]: fast_training(X, y, epochs=5001)
```

```
epochs: 0
epochs: 5000
X: [0 1] y: [0]
    Aproximacion: [0.07204406]
X: [0 0] y: [0]
    Aproximacion: [-0.07873938]
X: [1 0] y: [0]
    Aproximacion: [0.04653255]
X: [1 1] y: [1]
    Aproximacion: [0.78034912]
```

```
[12]: fast_training(X, y, epochs=50001)
```

```
epochs: 0
epochs: 5000
epochs: 10000
epochs: 15000
epochs: 20000
epochs: 25000
epochs: 30000
epochs: 35000
epochs: 40000
epochs: 45000
epochs: 50000
X: [0 1] y: [0]
    Aproximacion: [0.00034363]
X: [0 0] y: [0]
    Aproximacion: [-0.00028827]
X: [1 0] y: [0]
    Aproximacion: [0.00036937]
X: [1 1] y: [1]
    Aproximacion: [0.98325664]
```

OR

```
[13]: # And
X = np.array([[0, 1],
              [0, 0],
              [1, 0],
              [1, 1]])

y = np.array([[1],
              [0],
              [1],
              [1]])
```



```
[14]: fast_training(X, y)
```

```
epochs: 0
epochs: 5000
epochs: 10000
X: [0 1] y: [1]
    Aproximacion: [0.97629469]
X: [0 0] y: [0]
    Aproximacion: [0.00113128]
X: [1 0] y: [1]
    Aproximacion: [0.97815186]
X: [1 1] y: [1]
    Aproximacion: [0.99436356]
```

```
[15]: fast_training(X, y, epochs=5001)
```

```
epochs: 0
epochs: 5000
X: [0 1] y: [1]
    Aproximacion: [0.96028761]
X: [0 0] y: [0]
    Aproximacion: [0.00419791]
X: [1 0] y: [1]
    Aproximacion: [0.95119924]
X: [1 1] y: [1]
    Aproximacion: [0.9903503]
```

```
[16]: fast_training(X, y, epochs=50001)
```

```
epochs: 0
epochs: 5000
epochs: 10000
epochs: 15000
epochs: 20000
epochs: 25000
epochs: 30000
epochs: 35000
epochs: 40000
epochs: 45000
epochs: 50000
X: [0 1] y: [1]
    Aproximacion: [0.98773139]
X: [0 0] y: [0]
    Aproximacion: [0.00029107]
X: [1 0] y: [1]
    Aproximacion: [0.98918482]
X: [1 1] y: [1]
    Aproximacion: [0.99850818]
```

XOR

```
[17]: # And
X = np.array([[0, 1],
              [0, 0],
              [1, 0],
              [1, 1]])

y = np.array([[1],
              [0],
              [1],
              [0]])
```

```
[18]: fast_training(X, y)
```

```
epochs: 0
epochs: 5000
epochs: 10000
X: [0 1] y: [1]
    Aproximacion: [0.95353668]
X: [0 0] y: [0]
    Aproximacion: [0.00173207]
X: [1 0] y: [1]
    Aproximacion: [0.95132908]
X: [1 1] y: [0]
    Aproximacion: [0.00415304]
```

```
[19]: fast_training(X, y, epochs=5001)
```

```
epochs: 0
epochs: 5000
X: [0 1] y: [1]
    Aproximacion: [0.64351828]
X: [0 0] y: [0]
    Aproximacion: [0.18061695]
X: [1 0] y: [1]
    Aproximacion: [0.58315306]
X: [1 1] y: [0]
    Aproximacion: [0.3167121]
```

```
[20]: fast_training(X, y, epochs=50001)
```

```
epochs: 0
epochs: 5000
epochs: 10000
epochs: 15000
epochs: 20000
epochs: 25000
epochs: 30000
```

```

epochs: 35000
epochs: 40000
epochs: 45000
epochs: 50000
X: [0 1] y: [1]
    Aproximacion: [0.97937955]
X: [0 0] y: [0]
    Aproximacion: [0.00030344]
X: [1 0] y: [1]
    Aproximacion: [0.9796585]
X: [1 1] y: [0]
    Aproximacion: [0.00120609]

```

2.4 Referencias

[1]MIGALA D, TIPOS DE REDES NEURONALES ARTIFICIALES (2019) | INTELIGENCIA ARTIFICIAL. 2018.

[2]“Activation function”, Wikipedia. dic. 13, 2020, Consultado: dic. 16, 2020. [En línea]. Disponible en: https://en.wikipedia.org/w/index.php?title=Activation_function&oldid=993982136.

[3]S. Torres y N. Nadia, “Aplicación de Redes Neuronales en controladores de baterías”, dic. 2019, Consultado: dic. 16, 2020. [En línea]. Disponible en: <http://dspace.unila.edu.br:80/handle/123456789/5826>.

[4]P. J. Werbos, “Backpropagation through time: what it does and how to do it”, Proceedings of the IEEE, vol. 78, núm. 10, pp. 1550–1560, oct. 1990, doi: 10.1109/5.58337.

[5]“Backpropagation-BP – Numerentur.org”. <http://numerentur.org/backpropagation/> (consultado dic. 16, 2020).

[6]“Multicapa Sobreaprendizaje Perceptron Neuronas”. <https://web.archive.org/web/20140714231842/http://www.de-neuronas/perceptron-multicapa.html> (consultado dic. 16, 2020).

[]: